


论文精读：滚动轴承剩余寿命预测

Deep learning-based remaining useful life estimation of bearings using multi-scale feature extraction

Xiang Li, Wei Zhang, Qian Ding
Reliability Engineering & System Safety, 182 (2019), 208–218
DOI: <https://doi.org/10.1016/j.ress.2018.11.011>



Rolling bearing: vibration reflects degradation

面向机械可靠性设计：用振动信号提前估计轴承还能可靠工作多久

1. 论文信息与阅读主线

本页只交代论文对象；不展开期刊介绍。

论文对象

研究对象：滚动轴承 轴承是旋转机械关键件；故障会引发停机、二次损伤与安全风险。

任务：剩余寿命 RUL 预测

数据：PRONOSTIA 轴承加速退化实验

方法：时频信息 + 多尺度 CNN 特征提取

输出：每个监测时刻的 RUL 估计

为什么适合机械可靠性设计

本 PPT 讲解路径

问题背景

RUL 与退化数据

多尺度深度学习模型

实验验证与结果

对可靠性设计的启示

局限与可改进方向

2. 研究问题：从“能不能用”到“还能用多久”

传统故障诊断回答：轴承当前是否已经异常、属于哪类故障。


可靠性设计和维护更关心：在当前退化状态下，距离失效还有多少寿命余量。

RUL 预测把传感器监测数据转化为可执行的维护窗口，减少过早维修和突发停机。

难点在于轴承退化高度非线性：冲击、噪声、工况变化和个体差异都会干扰寿命估计。



3. RUL 概念：退化轨迹到失效阈值的时间距离




RUL (Remaining Useful Life) = 当前时刻到失效时刻的剩余运行时间或循环数。

退化指标可以来自振动幅值、频带能量、时频图像或深度网络自动学习的特征。

当退化指标穿越失效阈值时，认为轴承达到寿命终点。

预测越靠近真实 RUL ， 维修计划越能兼顾安全冗余和经济性。

4. 数据基础： PRONOSTIA 轴承加速退化实验



Rolling bearing: vibration reflects degradation


论文在公开、常用的 PRONOSTIA 滚动轴承数据集上验证方法。

实验记录轴承从健康运行到失效的全寿命振动信号，适合构造监督学习样本。

不同载荷 / 转速工况使数据更接近工程场景：同类轴承也可能呈现不同退化速度。


机械含义：振动信号中的冲击、频带能量和非平稳成分，是滚道 / 滚动体损伤扩展的外在表征。

5. 总体技术路线：原始振动信号到 RUL 估计



关键思想：不依赖大量手工特征，直接让深度网络从时频数据中学习退化模式。
多尺度结构使模型能同时关注局部冲击和较长时间范围的趋势变化。

6. 为什么要看时频信息？



图为教学示意，非论文原图

轴承早期损伤往往表现为弱冲击，直接从时域幅值中识别并不稳定。


频域能揭示故障相关频带和调制成分，但会弱化冲击出现的时间位置。

时频表达把“什么时候出现异常”和“异常集中在哪些频带”结合起来。

这为 CNN 的二维局部特征提取提供了类似图像的输入结构。

7. 方法核心：多尺度 CNN 特征提取

Multi-scale CNN extracts local impulses + broader degradation trends



不同卷积核 / 感受野相当于从不同“观察尺度”审视退化信号。

小尺度：更敏感于局部冲击、尖峰与短时异常。

中 / 大尺度：更适合捕捉频带能量变化和较慢的退化趋势。

多尺度特征融合后，再通过回归层输出 RUL。

与传统特征工程的区别

传统方法常需人工选择 RMS、峭度、包络谱等指标；论文方法把特征学习嵌入模型训练，降低对专家手工调参的依赖。

8. 监督学习构造：寿命标签、窗口样本与模型训练

样本

从全寿命振动序列中截取多个时间窗口。
每个窗口代表某个运行时刻的健康状态。

标签

根据该时刻到失效终点的距离生成 RUL 标签。
越接近失效，标签值越小。

训练目标

让网络学习“信号模式 → 剩余寿命”的映射。
测试时输入新轴承监测片段，即可输出 RUL。

9. 实验验证关注点：预测精度与工程可用性

数据划分：用部分轴承退化轨迹训练，在其他轴承轨迹上测试泛化能力。

比较对象：传统数据驱动方法、单一尺度 / 较浅模型等基线方案。

评价重点：预测误差是否更小、曲线是否更平滑、临近失效阶段是否仍保持可靠。

工程可用性：模型是否减少人工特征依赖，并能在实时监测中持续更新 RUL。

误差

预测值与真实 RUL 的偏差

稳定性

预测曲线是否剧烈跳动


提前量

是否能在失效前给出有效预警

泛化

不同轴承 / 工况下是否仍可用

10. 主要结果：多尺度深度特征提高 RUL 预测表现



论文报告：所提多尺度深度学习方法在 PRONOSTIA 轴承数据上取得较高 RUL 预测精度。


相较依赖手工特征或单一模型的方案，多尺度 CNN 能更充分挖掘退化信息。

模型输出的 RUL 曲线更接近真实寿命趋势，对预测性维护更有参考价值。

右图为教学示意：强调预测曲线与真实 RUL 的贴合关系，并非论文数值复刻。

11. 对可靠性设计的价值：把监测数据变成决策量

Closed-loop reliability design and PHM



RUL 不是单纯算法输出，而是连接“状态监测—维修决策—设计改进”的桥梁。

当 RUL 低于维护阈值，可安排检修、更换或降载运行，避免连锁故障。

多台设备的 RUL 分布可帮助制定备件库存与维修资源配置。

寿命预测误差和失效样本还能反向暴露结构、材料、润滑或装配的薄弱环节。

12. 机械可靠性视角：与失效机理如何对应？

物理退化

接触疲劳
滚道点蚀 / 剥落
滚动体损伤
润滑劣化
装配偏差与载荷冲击

可观测信号

振动幅值增加
冲击脉冲增多
频带能量迁移
时频图纹理变化
退化趋势非线性

可靠性量化

健康指标
失效阈值
RUL 分布或点估计
维护阈值
设计安全裕度

13. 局限与可改进方向

需要较充分的带标签全寿命退化数据；真实工厂中完整失效样本通常稀缺。

不同设备、载荷、转速、传感器安装位置会造成数据分布偏移，影响模型迁移。

深度模型可解释性有限：预测准确不等于清楚知道具体失效机理。

若只给出点估计 RUL，难以直接表达置信区间和风险水平。

后续可结合物理退化模型、迁移学习、不确定性量化和在线更新。

给机械研究生的思考

可靠性设计不应把深度学习当黑盒终点，而应把它作为连接监测数据与失效机理的工具。

工程落地重点

模型需要在目标设备上校准阈值、验证误报 / 漏报风险，并与维修制度联动。

研究延伸

可加入置信区间、寿命分布、成本函数和可靠性约束优化。

14. 总结：这篇论文给机械可靠性设计的三点启示

启示一

启示二

启示三

轴承可靠性评估可以从“离线寿命试验”扩展到“在线状态信息 + 多尺度特征有助于捕捉复杂非线性退化过程”的最终价值在于维护决策、风险控制和设计反馈。

Deep learning-based remaining useful life estimation of bearings using multi-scale feature extraction

论文链接

<https://doi.org/10.1016/j.ress.2018.11.011>
<https://www.sciencedirect.com/science/article/pii/S0951832018308299>

参考来源：论文摘要、 Highlights 、 DOI/ScienceDirect/INIS/IDEAS 元数据； PPT 中图示为教学重绘。